¿Se puede anticipar el resultado de un partido de selecciones?

Proyecto final · Python para Ciencia de Datos · 2026

Juan Apolo · Alen Cukier

2026-10-12

Tabla de contenidos

1 Introducción **2**

2 Datos **2**
- 2.1 Fuente . . . 2
- 2.2 Limpieza . . . 3
- 2.3 La variable a explicar . . . 4
- 2.4 Variables construidas: lo que se sabe antes del partido . . . 4
  - 2.4.1 ¿Funciona el Elo? . . . 5
- 2.5 Muestra final . . . 6

3 Análisis exploratorio **6**
- 3.1 ¿Cuántos partidos y qué resultados? . . . 6
- 3.2 ¿Cuántos goles se hacen? . . . 8
- 3.3 ¿Sirve el Elo? . . . 9
- 3.4 Uruguay . . . 11

4 Modelado **12**
- 4.1 Qué comparamos . . . 12
- 4.2 Modelo de referencia . . . 12
- 4.3 Árbol de decisión . . . 12
- 4.4 Random forest . . . 13
- 4.5 Comparación . . . 13
- 4.6 ¿Cuánto aporta cada tipo de información? . . . 14
- 4.7 Qué variables pesan . . . 15
- 4.8 Dónde se equivoca . . . 16
- 4.9 Uruguay en los datos de evaluación . . . 17

5 Comentarios finales **17**

6 Referencias **18**

1. Introducción

Un partido de fútbol tiene siempre algo de azar, pero los equipos no llegan al partido en igualdad de condiciones. Antes de que empiece ya sabemos quién viene ganando, quién juega de local y qué tan fuertes han sido históricamente las dos selecciones.

La pregunta que guía el trabajo es: ¿cuánto se puede anticipar el resultado de un partido de selecciones (victoria local, empate o victoria visitante) usando solo información disponible *antes* del pitazo inicial?

Para responderla:

- Partimos de la base de Kaggle con todos los partidos internacionales desde 1872.
- Construimos tres tipos de información previa al partido: la **fuerza histórica** de cada selección (un puntaje Elo que calculamos nosotros), su **forma reciente** (cómo le fue en los últimos 5 partidos) y el **contexto** (si la sede es neutral y si es un amistoso).
- Hacemos un análisis exploratorio para entender la base y ver si esas variables se relacionan con el resultado.
- Comparamos tres modelos de clasificación: una regla de referencia, un árbol de decisión y un random forest.

La variable a explicar es categórica con tres valores (`L`, `E`, `V`), así que el problema es de **clasificación**. No intentamos predecir el marcador exacto.

2. Datos

2.1. Fuente

Usamos **International football results from 1872 to 2026**, de Mart Jürisoo, publicada en Kaggle con licencia CC0. La copia que usamos está en `datos/results.csv` dentro de este repositorio, así que el trabajo corre sin descargar nada.

Cada fila es un partido de selecciones masculinas mayores. Incluye amistosos y competencias oficiales, y también selecciones no afiliadas a FIFA.

```
Filas y columnas: (49945, 9)
```

	date	home_team	away_team	home_score	away_score	tournament	city	country	neu
0	1872-11-30	Scotland	England	0	0	Friendly	Glasgow	Scotland	Fal
1	1873-03-08	England	Scotland	4	2	Friendly	London	England	Fal
2	1874-03-07	Scotland	England	2	1	Friendly	Glasgow	Scotland	Fal
3	1875-03-06	England	Scotland	2	2	Friendly	London	England	Fal
4	1876-03-04	Scotland	England	3	0	Friendly	Glasgow	Scotland	Fal

	tipo
date	datetime64[us]
home_team	str
away_team	str
home_score	int64
away_score	int64
tournament	str
city	str
country	str
neutral	bool

Las variables originales son:

Variable	Tipo	Significado
`date`	fecha	día del partido
`home_team`, `away_team`	categórica	selección local y visitante
`home_score`, `away_score`	numérica	goles de cada equipo al final (incluye alargue, no penales)
`tournament`	categórica	competencia
`city`, `country`	categórica	sede
`neutral`	booleana	si se jugó en cancha neutral

2.2. Limpieza

Revisamos valores faltantes, duplicados y valores imposibles antes de trabajar.

	faltantes
date	0
home_team	0
away_team	0
home_score	0
away_score	0
tournament	0
city	0
country	0
neutral	0

```
Duplicados exactos: 0
Goles negativos: 0
Equipo contra sí mismo: 0
Rango de fechas: 1872-11-30 a 2026-10-06
```

La base está muy limpia: no hay faltantes ni duplicados. Lo único que hacemos es **cortar en el 31/12/2025**, porque 2026 está incompleto y mezclarlo distorsionaría los conteos por año.

```
Partidos hasta 2025: 49144
```

2.3. La variable a explicar

Creamos `resultado` comparando los goles: `L` si ganó el local, `E` si empataron y `V` si ganó el visitante. Agregamos también el total de goles, que usamos en el análisis exploratorio.

resultado	proporción
L	0.490
V	0.283
E	0.227

Una aclaración importante: "local" y "visitante" son los roles que figuran en la base. Cuando la sede es neutral (un Mundial, por ejemplo), el equipo marcado como local **no está jugando en su casa**. Lo tenemos en cuenta más adelante.

2.4. Variables construidas: lo que se sabe antes del partido

No podemos usar los goles del propio partido para predecir su resultado: sería hacer trampa. Lo que sí podemos usar es **lo que pasó antes**. Construimos dos cosas.

Puntaje Elo. Es un número que resume qué tan fuerte viene siendo una selección. Después de cada partido el ganador le saca puntos al perdedor, y cuántos depende de qué tan esperable era ese resultado.

¿Pero si todas arrancan en 1500, cómo sabe el Elo quién es fuerte y quién es débil? Al principio no lo sabe, y justamente por eso todas arrancan iguales. En el primer partido entre dos selecciones nuevas el sistema las considera parejas y se intercambian 10 puntos, sin importar quiénes sean. **Las diferencias no se las damos nosotros: aparecen solas a medida que se juegan partidos.** El que gana seguido sube, el que pierde seguido baja, y después de unas decenas de partidos los números ya separan a los equipos. El primer partido de la base es de 1872 y nuestra muestra arranca en 1990: para entonces cada selección arrastra más de un siglo de resultados y su Elo ya significa algo. Por eso también exigimos un mínimo de 10 partidos previos.

Una vez que las diferencias existen, el ajuste deja de ser simétrico. Con un equipo de 1800 contra uno de 1500 en cancha neutral, el sistema espera que gane el fuerte con probabilidad 0.85. Si gana, suma apenas **+3 puntos**: era lo previsible. Si pierde, se lleva **−17**: el batacazo obliga a corregir mucho más.

¿Y qué es `K = 20`? Es **el máximo de puntos que pueden cambiar de manos en un partido**, y por lo tanto la perilla que regula qué tan rápido reacciona el puntaje. Con un `K` grande el Elo se mueve mucho en cada partido: refleja enseguida un cambio de nivel, pero se sacude con cualquier

resultado raro. Con un `K` chico es estable pero tarda años en registrar que un equipo mejoró. 20 es el valor intermedio habitual y es el que usamos, sin optimizarlo.

Por último, le damos **60 puntos de ventaja al local** cuando la sede no es neutral, para que el sistema no premie a un equipo por ganar en su casa, que es lo esperable.

Forma reciente. El promedio de puntos (3 por victoria, 1 por empate, 0 por derrota) y los goles a favor y en contra en los **últimos 5 partidos** de cada selección.

Las dos se calculan recorriendo los partidos en orden cronológico: para cada partido **primero leemos** el Elo y la forma que los equipos traían, y **recién después** los actualizamos con lo que pasó. Así ningún partido usa información de su propio resultado ni del futuro.

```
Elo y forma calculados para 49144 partidos
```

Con eso armamos las variables que entran al modelo. Trabajamos con **diferencias** (local menos visitante) porque lo que importa no es el nivel absoluto sino quién es más fuerte de los dos, y con **promedios** para tener una idea del nivel del partido.

	elo_dif	elo_medio	pts_dif	gf_dif	gc_dif	sede_neutral	es_amistoso
count	49144.00	49144.00	48842.00	48842.00	48842.00	49144.00	49144.00
mean	7.41	1547.66	0.03	0.03	-0.04	0.26	0.37
std	159.75	117.89	0.98	1.13	1.31	0.44	0.48
min	-853.32	1090.74	-3.00	-14.40	-19.60	0.00	0.00
25 %	-90.29	1473.41	-0.60	-0.60	-0.60	0.00	0.00
50 %	7.31	1540.65	0.00	0.00	0.00	0.00	0.00
75 %	106.60	1624.09	0.60	0.60	0.60	1.00	1.00
max	819.91	1973.97	3.00	16.00	20.00	1.00	1.00

2.4.1. ¿Funciona el Elo?

Antes de usarlo para modelar conviene comprobar que el puntaje tenga sentido. La prueba más simple es mirar quiénes quedaron arriba al cerrar 2025.

	Elo
Argentina	1995.0
Spain	1987.0
France	1929.0
Brazil	1922.0
Colombia	1908.0
England	1893.0
Portugal	1881.0
Netherlands	1865.0
...	
Uruguay	1831

El resultado es tranquilizador: arriba aparecen Argentina, España, Francia y Brasil, y Uruguay queda entre los mejores sin estar en el podio. **Nunca le dijimos al programa quién era bueno**: todas las selecciones arrancaron en 1500 y este orden salió solo, de procesar 49.144 partidos en orden cronológico. Que coincida razonablemente con lo que uno esperaría es la señal de que la variable sirve.

2.5. Muestra final

Nos quedamos con los partidos **desde 1990** y exigimos que las dos selecciones tengan al menos 10 partidos previos. Sin esa historia, el Elo todavía vale 1500 y la forma reciente no significa nada.

```
Partidos en la muestra: 31177
Desde 1990-01-12 hasta 2025-12-31
Selecciones distintas: 275
```

3. Análisis exploratorio

Las preguntas que nos hacemos acá son cuatro:

1. ¿Cuántos partidos hay y cómo se reparten los resultados?
2. ¿De verdad conviene ser local?
3. ¿Cuántos goles se hacen por partido?
4. ¿La diferencia de Elo se relaciona con el resultado?

> Todo el análisis exploratorio usa **solo los datos de entrenamiento** (hasta 2018). No miramos los años que después usamos para evaluar, para no dejarnos influir por ellos al elegir el modelo.

```
Entrenamiento: 24338 partidos (1990-01-12 a 2018-12-31)
Evaluación:     6839 partidos (2019-01-02 a 2025-12-31)
```

Partimos **por fecha y no al azar**. Si mezcláramos los años, el modelo podría entrenar con partidos de 2020 y predecir partidos de 2010, que es justamente lo contrario de lo que queremos: anticipar lo que todavía no pasó.

3.1. ¿Cuántos partidos y qué resultados?

Lo que salta a la vista: la cantidad de partidos se duplicó. Se arranca en 1990 con 466 y se llega al pico en **2011, con 1105 partidos**, más del doble.

El dibujo de dientes de sierra tampoco es casualidad: los años de Mundial y Eurocopa concentran más encuentros que los años intermedios. Y el salto de los primeros noventa se explica porque aparecen de golpe las selecciones de los países que surgen de la disolución de la URSS y Yugoslavia.

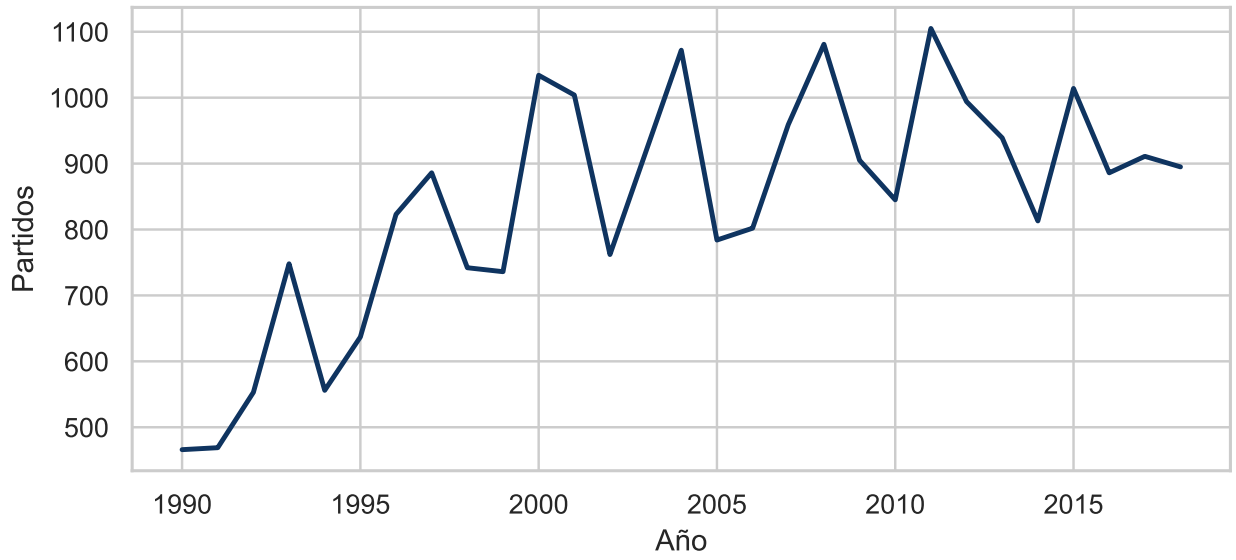


Figura 1: Partidos por año en la muestra de entrenamiento.

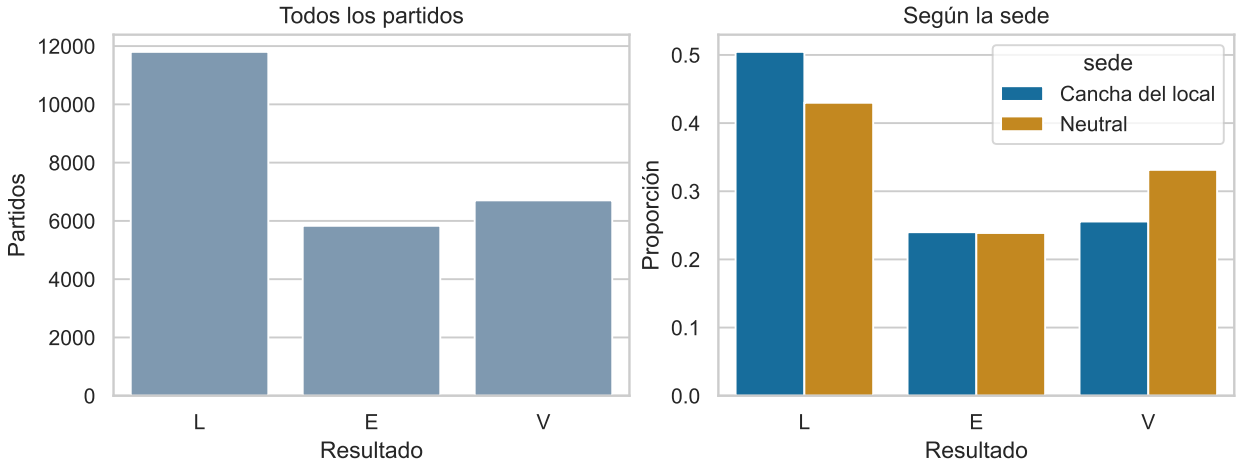


Figura 2: Distribución del resultado, en total y según el tipo de sede.

resultado sede	L	E	V
Cancha del local	0.504	0.240	0.256
Neutral	0.430	0.239	0.331

Acá aparece el primer hallazgo claro. **En cancha propia el local gana el 50 % de los partidos; en cancha neutral baja al 43 %**, y esos siete puntos se los lleva casi enteros el visitante, que pasa del 26 % al 33 %. La localía existe y se mide.

Vale la pena notar que, aun en sede neutral, el equipo designado como local sigue ganando más que el visitante. Eso no es ventaja de cancha: en un Mundial o una Copa América el "local" de la planilla suele ser el equipo mejor rankeado o el del país anfitrión. Es un recordatorio de que la etiqueta `neutral` no separa dos grupos comparables.

También se ve algo que va a complicarnos el modelado: **el empate nunca es la categoría más frecuente**. Ronda el 24 % y está siempre en el medio, lo que lo hace muy difícil de acertar.

3.2. ¿Cuántos goles se hacen?

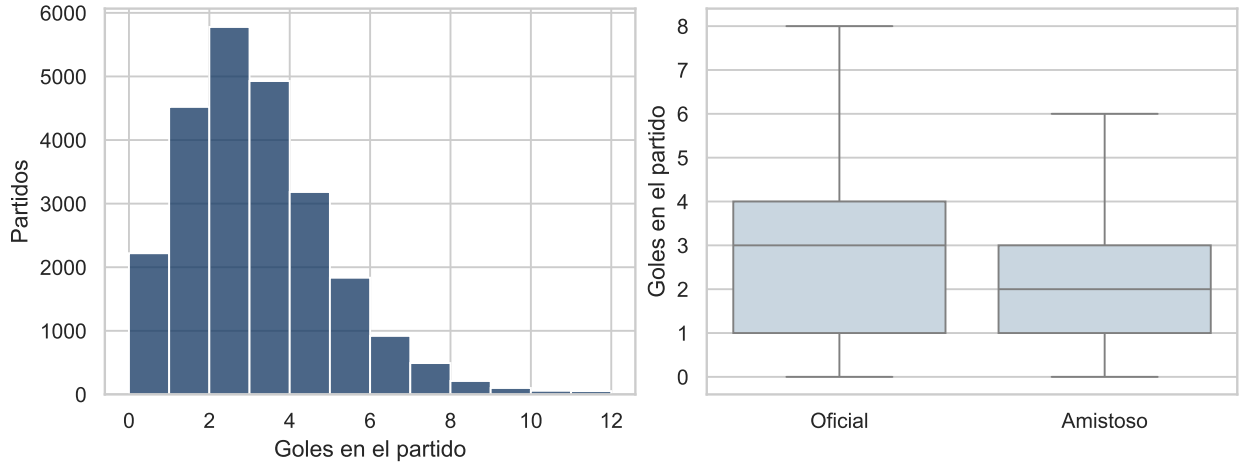


Figura 3: Goles por partido y resultado según el tipo de torneo.

```
Media:   2.72 goles por partido
Mediana: 2
Máximo:  31
```

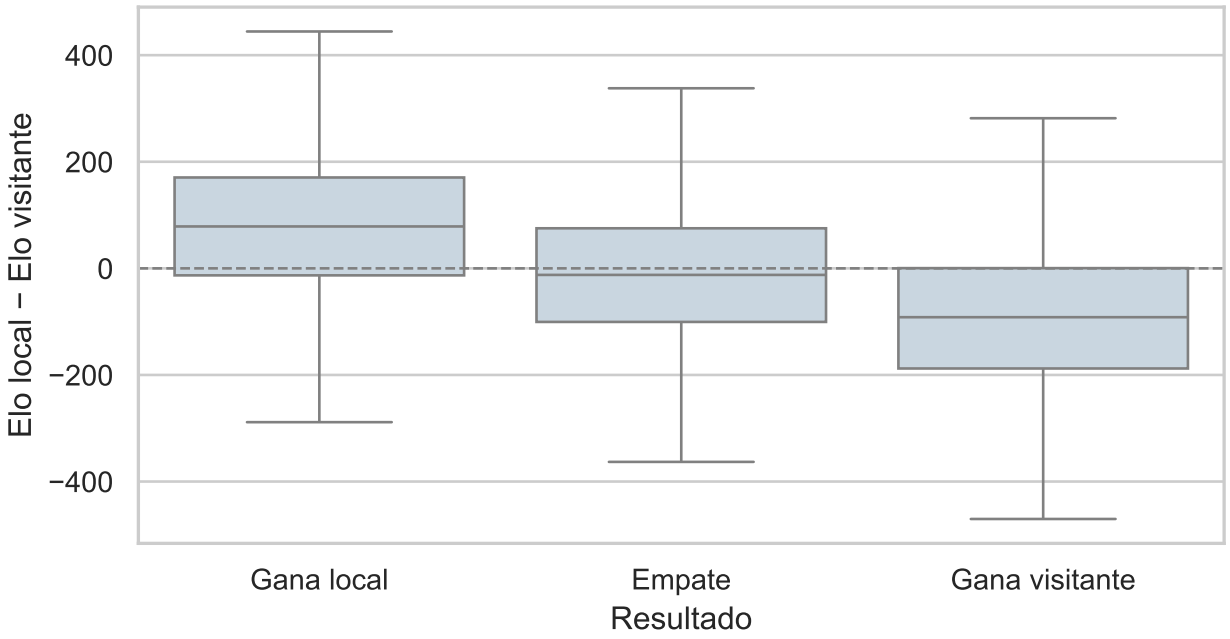
Lo más común son 2 goles por partido (5778 casos), seguido de 3 y de 1. Un 9 % de los partidos termina 0 a 0.

La distribución está corrida a la derecha: hay una cola larga de goleadas que empuja la media (2.72) por encima de la mediana (2). Por eso conviene mirar el histograma entero y no quedarse con el promedio.

El outlier es espectacular: el partido con más goles de toda la muestra es un **Australia 31 – 0 American Samoa** de abril de 2001, por eliminatorias del Mundial. Dos días antes, el mismo Australia le había ganado 22 a 0 a Tonga. No son errores de carga: pasaron de verdad, y son la razón por la que el máximo del eje llega tan lejos.

Entre amistosos y partidos oficiales, en cambio, casi no hay diferencia de goles. Las dos cajas están prácticamente a la misma altura.

3.3. ¿Sirve el Elo?



(a) Diferencia de Elo antes del partido, según el resultado que terminó dándose.

	Elo dif. media
resultado	
L	83.0
E	-14.3
V	-102.2

(b)

Figura 4

Esta es la figura más importante del análisis exploratorio. **Los partidos que terminan en victoria local son, en promedio, partidos en los que el local ya venía siendo más fuerte**: unos 83 puntos de Elo por encima. En las victorias visitantes la diferencia media es de −102, y los empates quedan justo en el medio, cerca del cero (−14).

Que las cajas se superpongan tanto es también informativo: el Elo ayuda, pero está lejos de determinar el resultado. Hay muchísimos partidos en que gana el más débil.

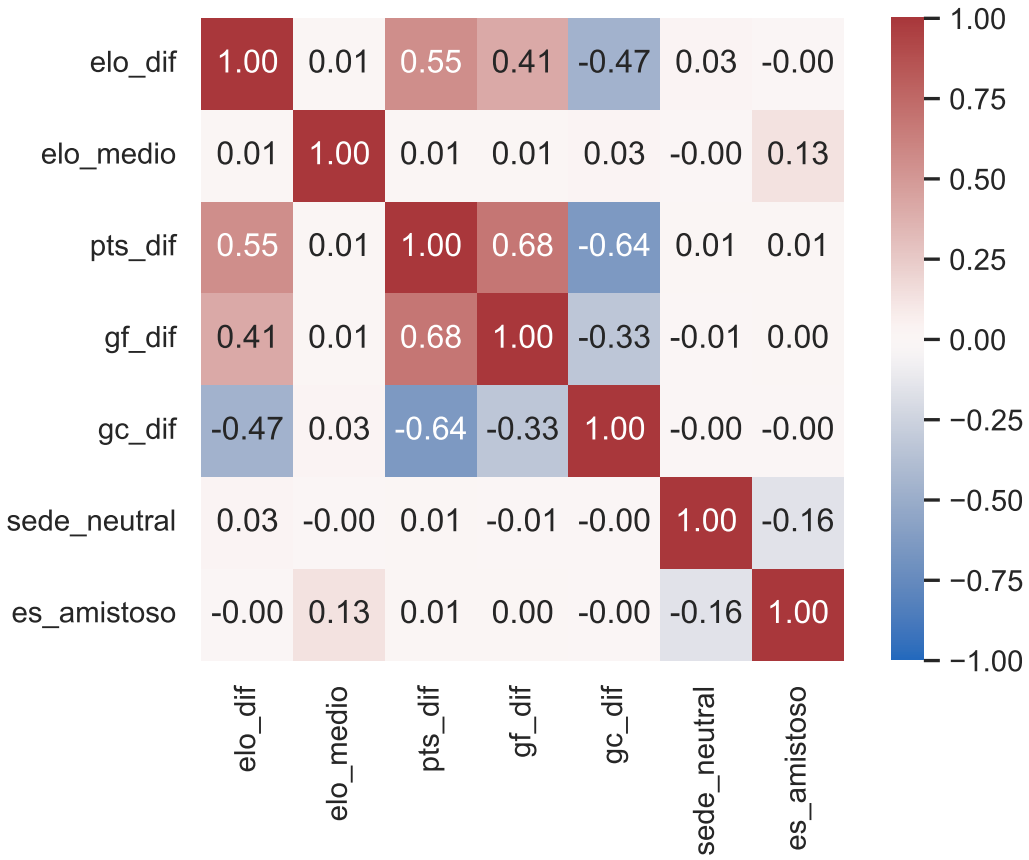


Figura 5: Correlaciones entre las variables construidas.

El rojo más fuerte está entre `pts_dif` y `gf_dif` (+0.68), y el azul más fuerte entre `pts_dif` y `gc_dif` (−0.64). Era esperable: el equipo que viene sumando más puntos es el que viene haciendo más goles y recibiendo menos. Las tres variables de forma miden casi lo mismo desde ángulos distintos.

`elo_dif` tiene una correlación moderada con la forma (+0.55 con `pts_dif`), lo cual también tiene sentido: el que viene fuerte hace tiempo suele venir bien ahora.

El dato que importa para el modelo es otro: `elo_dif` y `elo_medio` tienen correlación **+0.01**, o sea prácticamente cero. Son independientes, y eso es bueno: una dice *quién* es más fuerte y la otra *qué tan bueno* es el partido en general. Aportan información distinta.

Que las variables de forma estén tan correlacionadas entre sí no rompe un árbol ni un random forest, pero sí explica por qué más adelante varias aparecen con importancia baja: el modelo se apoya en una y las otras quedan de sobra.

3.4. Uruguay



Figura 6: Trayectoria del Elo de Uruguay desde 1990.

La curva tiene su punto más bajo a fines de los noventa (1624 puntos de promedio en 1997, los años en que Uruguay no se clasificó a dos Mundiales seguidos) y a partir de ahí sube de forma bastante sostenida: 1717 en 2007, 1767 en 2011 y por encima de 1800 desde 2014. El promedio más alto de toda la serie es el de **2024**, con 1860 puntos.

Conviene leer esto con cuidado. El Elo es acumulativo y no se reinicia nunca, así que una selección que gana de manera consistente durante años va acumulando puntos sin un techo natural. Que el máximo esté al final de la serie no prueba por sí solo que este sea el mejor Uruguay de la historia; dice que viene sumando más de lo que pierde desde hace tiempo.

4. Modelado

4.1. Qué comparamos

La variable a explicar es `resultado` (`L`, `E`, `V`). Comparamos tres opciones, de la más simple a la más compleja:

1. **Referencia:** predecir siempre la categoría más frecuente del entrenamiento. Es el piso que hay que superar; cualquier modelo que no le gane, no sirve.
2. **Árbol de decisión** con profundidad limitada, que tiene la ventaja de poder dibujarse y leerse.
3. **Random forest**, que promedia muchos árboles y suele andar mejor, a costa de ser menos interpretable.

Evaluamos con **accuracy** (proporción de aciertos), la matriz de confusión y el `classification_report`, que muestra precisión y recall categoría por categoría.

```
Entrenamiento: (24338, 7)
Evaluación:    (6839, 7)
```

4.2. Modelo de referencia

```
La categoría más frecuente en entrenamiento es 'L' (Gana local)
Accuracy de predecir siempre 'L': 0.477
```

4.3. Árbol de decisión

Empezamos con un árbol poco profundo. No es el que mejor anda, pero se puede dibujar y entender de un vistazo qué está mirando.

```
Accuracy del árbol en evaluación: 0.603
```

El árbol confirma lo del análisis exploratorio, y de una forma más contundente de lo esperado: **los tres primeros cortes los hace por `elo_dif`**. Primero separa en -2.85 (es decir, prácticamente en cero: quién es más fuerte), y después vuelve a cortar la misma variable en -138 y en $+141$. Con tres niveles disponibles, el árbol los gasta enteros en partir la diferencia de Elo en cuatro tramos, sin mirar ninguna otra variable.

Y hay algo todavía más llamativo: **ninguna hoja predice empate**. El árbol nunca apuesta a `E`, porque el empate no es la categoría más probable en ninguno de esos tramos. Volvemos sobre esto al final.

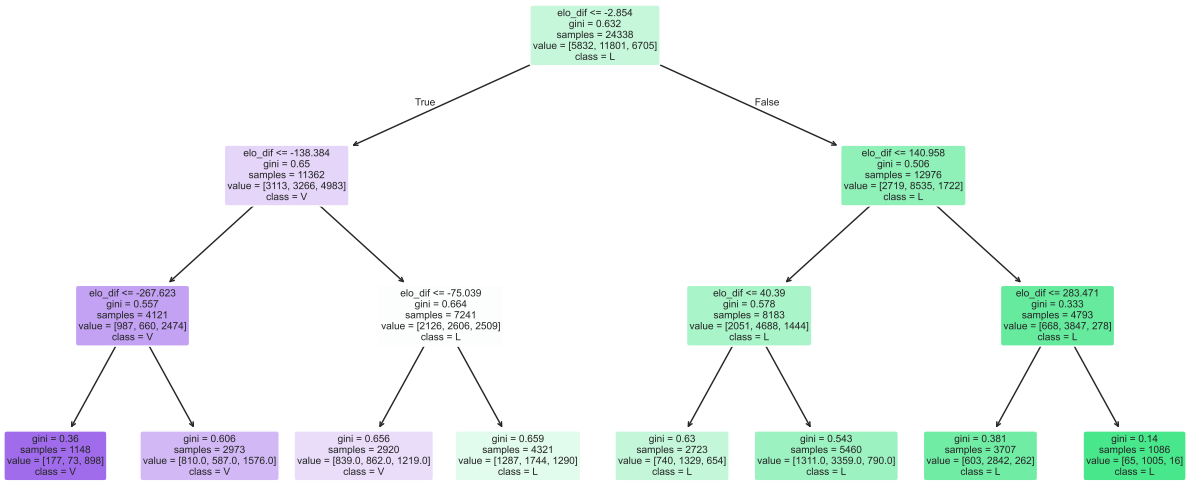


Figura 7: Árbol de decisión de profundidad 3.

4.4. Random forest

Un solo árbol es inestable: cambiando un poco los datos de entrada, cambia bastante. El random forest entrena muchos árboles sobre muestras distintas y promedia, lo que lo hace más estable.

Elegimos los hiperparámetros con `GridSearchCV`, que prueba todas las combinaciones usando validación cruzada **dentro del entrenamiento**, sin tocar los datos de evaluación.

```
Mejores hiperparámetros: {'max_depth': 8, 'min_samples_leaf': 5}
Accuracy en validación cruzada: 0.576
```

```
Accuracy del random forest en evaluación: 0.608
```

Comprobamos también qué tan estable es el resultado dentro del entrenamiento, con validación cruzada:

```
Accuracy por partición: [0.577 0.576 0.576 0.576 0.576]
Promedio: 0.576 ± 0.001
```

La variación entre particiones es chica, así que el número no depende de haber tenido suerte con una división particular.

4.5. Comparación

	Modelo	Accuracy
0	Referencia (siempre local)	0.477
1	Árbol de decisión	0.603
2	Random forest	0.608

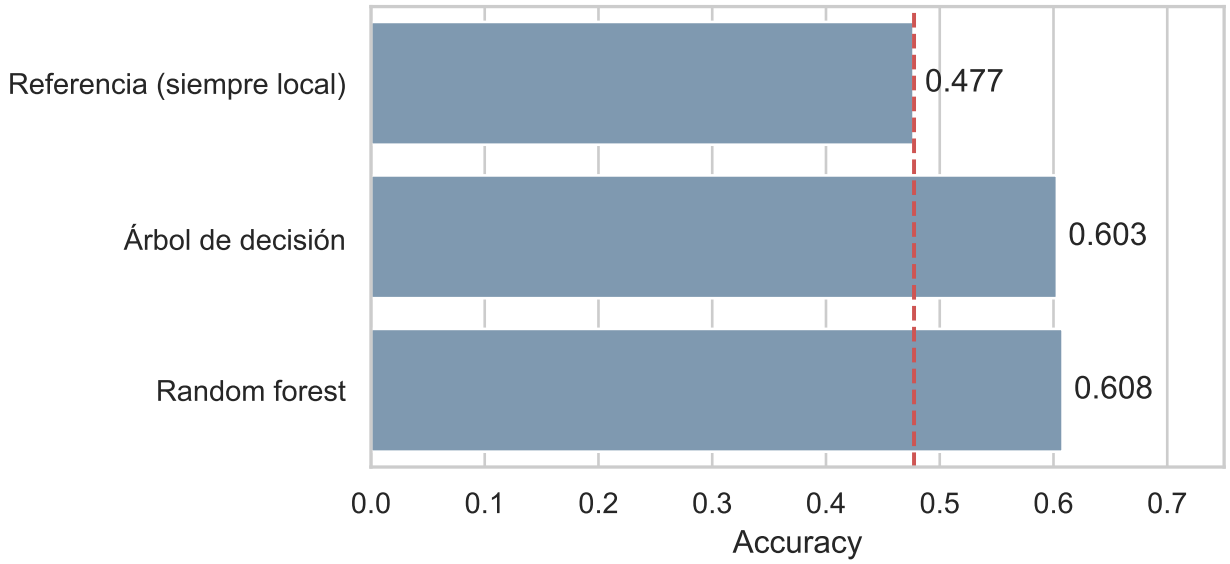


Figura 8: Accuracy de los tres modelos en los datos de evaluación.

Los dos modelos superan a la referencia con holgura: **13 puntos porcentuales** por encima de predecir siempre "gana el local". La información previa al partido **sí aporta**.

Ahora bien, entre el árbol y el random forest la diferencia es mínima (0.603 contra 0.608). Toda la mejora viene de usar las variables; apenas nada viene de usar un modelo más sofisticado. Es un resultado común y conviene decirlo: acá el trabajo lo hicieron los datos, no el algoritmo.

4.6. ¿Cuánto aporta cada tipo de información?

Si el modelo no mejora por ser más complejo, la pregunta pasa a ser **cuál de las variables está haciendo el trabajo**. Lo medimos directamente: entrenamos el mismo random forest con distintos subconjuntos y comparamos.

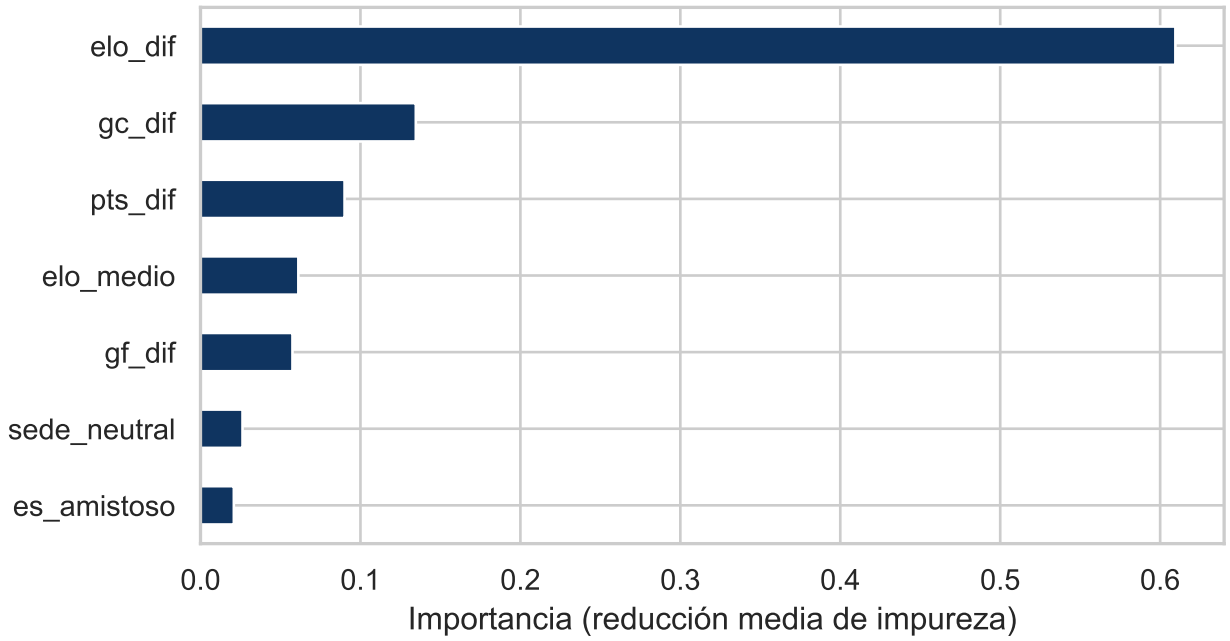
	Variables	Accuracy
0	Referencia (siempre local)	0.477
1	Solo contexto (sede + amistoso)	0.477
2	Contexto + forma reciente (sin Elo)	0.540
3	Solo elo_dif	0.604
4	Todas las variables	0.608

Esta tabla es, probablemente, el resultado más importante del trabajo:

- **El contexto solo no sirve para nada.** Saber si la sede es neutral y si es amistoso da 0.477, exactamente lo mismo que predecir siempre "gana el local". Cero aporte.
- **La forma reciente aporta, pero poco.** Sumarla lleva a 0.540: seis puntos sobre la referencia. Mirar los últimos 5 partidos es una muestra chica y ruidosa, y un equipo fuerte que viene de dos empates parece flojo.
- **El Elo solo es casi todo el modelo.** Con `elo_dif`, **una única columna**, se llega a 0.604. Las otras seis variables juntas agregan 0.004.

La conclusión es clara: **lo que permite anticipar el resultado es saber cuál de los dos equipos es históricamente más fuerte.** Todo lo demás es marginal. Esto también justifica haberse tomado el trabajo de construir el Elo: sin él, el modelo pasa de +13 puntos sobre la referencia a +6, menos de la mitad.

4.7. Qué variables pesan



(a) Importancia de cada variable en el random forest.

	importancia
elo_dif	0.610
gc_dif	0.135
pts_dif	0.090
elo_medio	0.061
gf_dif	0.058
sede_neutral	0.026
es_amistoso	0.021

(b)

Figura 9

`elo_dif` domina con holgura: se lleva el 61 % de la importancia total. La fuerza histórica relativa es, de lejos, lo que más informa. Le siguen las variables de forma reciente (`gc_dif` con 0.14 y `pts_dif` con 0.09) y recién después `elo_medio`. `sede_neutral` y `es_amistoso` quedan últimas, con menos del 3 % cada una.

Que `sede_neutral` pese tan poco llama la atención, porque en el análisis exploratorio se veía claramente que la sede importa. La explicación más probable es que el Elo ya absorbe buena parte de ese efecto: como lo calculamos dando ventaja al local en cancha propia, los equipos que juegan mucho de local ya llegan con un Elo que refleja esa condición.

Una advertencia: esta importancia mide cuánto usa el modelo cada variable, no cuánto "causa" cada una. Como varias variables están correlacionadas entre sí, el bosque puede apoyarse en una y dejar las otras con importancia baja aunque contengan información parecida.

4.8. Dónde se equivoca

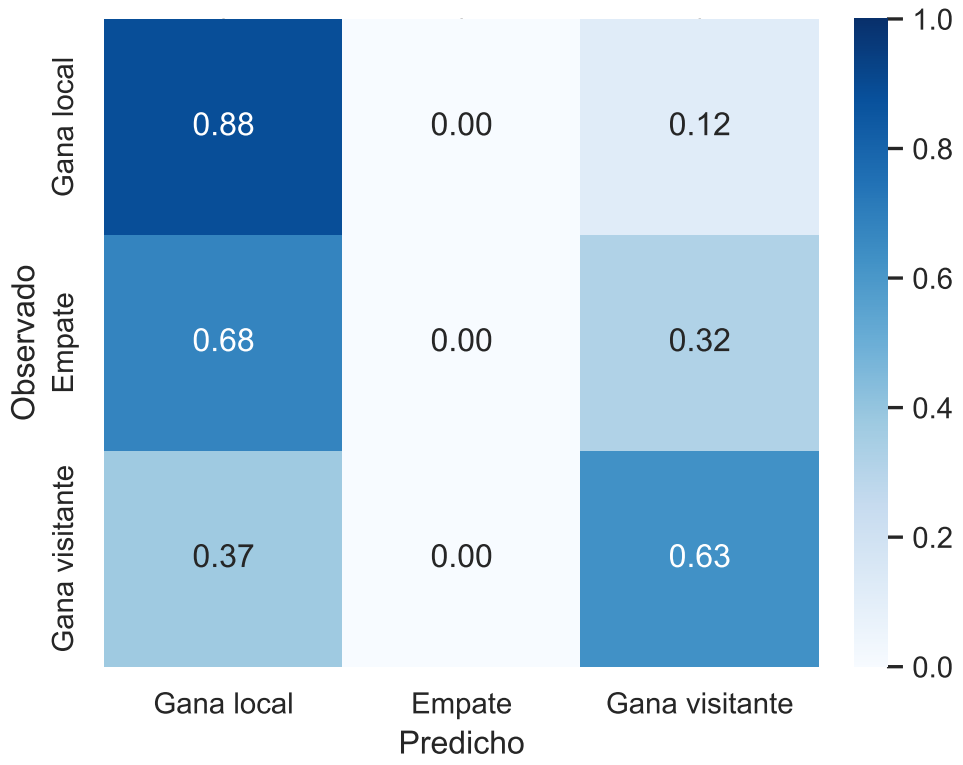


Figura 10: Matriz de confusión del random forest, en proporción de cada fila.

	precision	recall	f1-score	support
Gana local	0.62	0.88	0.73	3265
Empate	0.60	0.00	0.01	1555
Gana visitante	0.59	0.63	0.61	2019
accuracy			0.61	6839

```
    macro avg       0.60      0.50      0.45      6839
 weighted avg       0.60      0.61      0.53      6839
```

La fila del medio es la que cuenta la historia. En la matriz, la diagonal debería ser oscura si el modelo acierta. Las victorias locales se reconocen bien (**88 %**) y las visitantes razonablemente (**63 %**), pero el empate queda en **0.4 %**: de 1555 empates reales, el modelo detecta 6. En toda la evaluación arriesga un empate apenas 10 veces, sobre 6839 partidos.

Acá está la limitación más seria del trabajo, y conviene decirla sin vueltas: **el modelo prácticamente no predice empates.**

El motivo es estructural. El empate es la categoría menos frecuente y, sobre todo, **nunca es la más probable**: incluso en el partido más parejo imaginable, la probabilidad de empate ronda el 25–30 %, mientras que las de victoria local y visitante se reparten el resto. Como el modelo elige siempre la categoría más probable, el empate nunca gana esa comparación. Es una consecuencia de cómo decide el clasificador, no de que las variables no sirvan.

4.9. Uruguay en los datos de evaluación

```
Partidos de Uruguay entre 2019 y 2025: 81
Accuracy del modelo en esos partidos: 0.519
```

	date	home_team	away_team	home_score	away_score	resultado	prediccion
48238	2025-03-21	Uruguay	Argentina	0	1	V	V
48331	2025-03-25	Bolivia	Uruguay	0	0	E	V
48390	2025-06-05	Paraguay	Uruguay	2	0	L	V
48507	2025-06-10	Uruguay	Venezuela	2	0	L	L
48603	2025-09-04	Uruguay	Peru	3	0	L	L
48723	2025-09-09	Chile	Uruguay	0	0	E	V
48802	2025-10-10	Uruguay	Dominican Republic	1	0	L	L
48857	2025-10-13	Uzbekistan	Uruguay	1	2	V	V
48985	2025-11-15	Mexico	Uruguay	0	0	E	L
49020	2025-11-18	United States	Uruguay	5	1	L	V

En los partidos de Uruguay el modelo anda parecido que en el total. Es una muestra chica, así que el número hay que tomarlo como una curiosidad más que como una validación.

5. Comentarios finales

Lo que encontramos. Sí se puede anticipar parcialmente el resultado de un partido de selecciones con información previa. El random forest acierta el 61 % de los partidos contra el 48 % de la regla de referencia: **13 puntos porcentuales de mejora**. La variable que más aporta es, de lejos, la **diferencia de fuerza histórica** medida con el Elo, que concentra el 61 % de la importancia del modelo. La **localía** también importa: en cancha propia el local gana el 50 % de los partidos y en cancha neutral el 43 %. La forma reciente agrega algo, pero bastante menos que el Elo.

Vale la pena subrayar que el árbol de decisión simple acierta casi lo mismo que el random forest (60.3 % contra 60.8 %). La mejora vino de construir buenas variables, no de usar un modelo más complejo.

Lo que no pudimos. El modelo no predice empates. Como el empate nunca es la categoría más probable, un clasificador que elige el máximo nunca lo elige. Esto baja el accuracy global y, sobre todo, significa que el modelo es malo justo en los partidos más parejos, que son los interesantes.

Limitaciones.

- El Elo es nuestro, con parámetros fijos (`K = 20`, ventaja de 60) que no optimizamos. No es el ranking FIFA.
- Los marcadores incluyen alargue pero no penales, así que una final ganada por penales figura como empate.
- La base incluye amistosos y selecciones no afiliadas a FIFA, y la cobertura histórica es despareja.
- Los partidos no son independientes entre sí: las mismas selecciones aparecen muchas veces.
- Dejamos fuera a las selecciones con menos de 10 partidos previos, así que las conclusiones no aplican a equipos nuevos.

Qué se podría hacer después.

- Trabajar con las **probabilidades** (`predict_proba`) en lugar de la categoría predicha. Eso permitiría decir "este partido tiene 30 % de chance de empate" en vez de forzar una única respuesta, que es lo que realmente limita al modelo hoy.
- Probar a bajar el umbral de decisión para el empate, o reagrupar el problema en dos categorías (local gana / no gana).
- Agregar variables que no tenemos: días de descanso, si es partido de eliminatoria o de fase final, distancia de viaje.
- Probar valores de `K` y ventanas de forma distintos, para ver qué tan sensible es el resultado a esas decisiones.

6. Referencias

1. Jürisoo, M. *International football results from 1872 to 2026*. Kaggle. Licencia CC0.
2. Materiales del curso *Python para Ciencia de Datos* (2026), clases 1 a 14.
3. Documentación de scikit-learn, pandas y seaborn.